LAPORAN PRAKTIKUM DATA MINING

ANALISIS ASSOCIATION RULE PADA TRANSAKSI ONLINE RETAIL

Muhammad Fardan Hafidz - 5054251021

1. Ringkasan Tugas dan Karakteristik Dataset

Praktikum ini bertujuan untuk menemukan pola hubungan atau asosiasi antar produk dalam dataset transaksi ritel menggunakan metode *Association Rule Mining* (algoritma **FP-Growth** dan **Apriori**) serta mengevaluasi aturan asosiasi yang terbentuk menggunakan metrik **Support**, **Confidence**, dan **Lift**. Dataset yang digunakan adalah **Online Retail** dari UCI Machine Learning Repository (541.909 baris dan 8 atribut), yang merekam transaksi ritel online berbasis non-toko di Inggris (UK) pada periode **01/12/2010 hingga 09/12/2011**.

Nama Variabel	Peran	Tipe Data	Deskripsi Atribut	Missing Values
InvoiceNo	ID	Categorical	Nomor unik 6 digit per transaksi. Awalan huruf 'C' menandakan pembatalan.	0 (0,00%)
StockCode	ID	Categorical	Kode unik 5 digit untuk setiap produk/item yang berbeda.	0 (0,00%)
Description	Feature	Categorical	Nama produk (item) yang dibeli pelanggan.	1.454 (0,27%)
Quantity	Feature	Integer	Jumlah unit setiap produk per transaksi.	0 (0,00%)
InvoiceDate	Feature	Datetime	Tanggal dan waktu ketika setiap transaksi dibuat.	0 (0,00%)
UnitPrice	Feature	Continuous	Harga produk per unit dalam mata uang Poundsterling (£).	0 (0,00%)
CustomerID	Feature	Categorical	Nomor unik 5 digit untuk mengidentifikasi setiap pelanggan.	135.080 (24,93%)
Country	Feature	Categorical	Nama negara tempat tinggal pelanggan (90,36% transaksi berasal dari UK).	0 (0,00%)

2. Eksplorasi dan Pembersihan Data (Data Cleaning)

Kolom utama yang relevan untuk analisis *Association Rule* adalah **InvoiceNo** (pengenal keranjang transaksi), **Description** (nama item produk), dan **Quantity** (validasi pembelian positif). Pembersihan dilakukan terhadap tiga anomali: (1) menghapus **1.454 baris** dengan *Description* kosong (NaN), (2) menghapus **9.288 baris** transaksi dibatalkan (*InvoiceNo* diawali huruf 'C'), dan (3) menghapus **10.624 baris** dengan *Quantity* ≤ 0, serta merapikan spasi nama produk.

Metrik Evaluasi Dataset	Sebelum Pembersihan	Sesudah Pembersihan	Selisih / Reduksi Data
Jumlah Baris Data	541.909 baris	**530.693 baris**	-11.216 baris (-2,07%)
Jumlah Invoice Unik (Keranjang)	25.900 invoice	**20.136 invoice**	-5.764 invoice (-22,25%)
Jumlah Produk Unik (Description)	4.223 produk	**4.065 produk**	-158 item anomali (-3,74%)

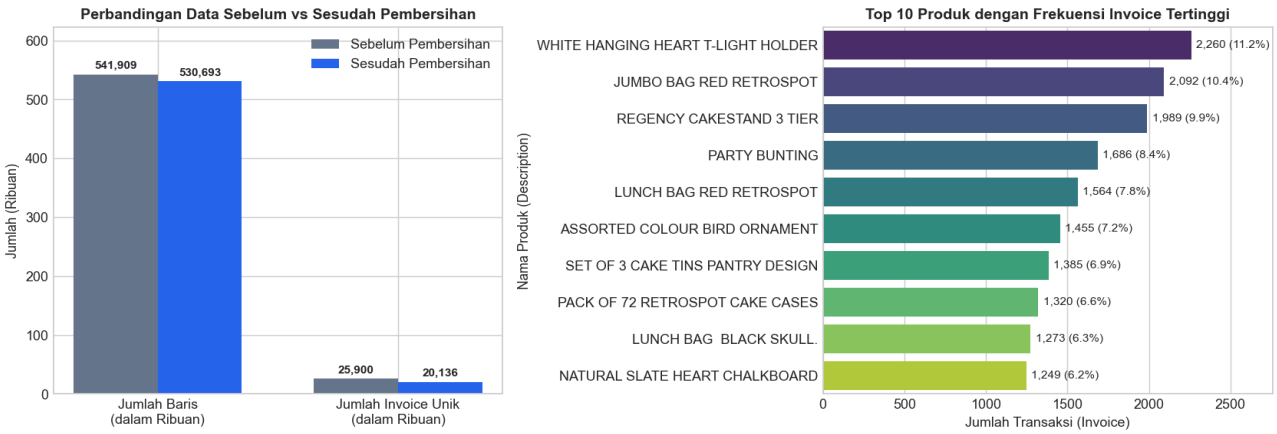


Diagram Perbandingan Data Sebelum vs Sesudah Pembersihan (Kiri) & Top 10 Produk Terlaris (Kanan)

3. Persiapan Data Transaksi (One-Hot Basket Encoding)

- **Agregasi Berbasis Invoice:** Sebanyak 530.693 baris transaksi bersih dikelompokkan berdasarkan *InvoiceNo* sehingga terbentuk **20.136 daftar belanja**, di mana setiap transaksi memuat himpunan produk unik yang dibeli bersama.
- **Transformasi One-Hot Basket:** Menggunakan *TransactionEncoder* dari pustaka **mlxtend**, daftar belanja diubah menjadi matriks biner (*True/False*) berukuran **20.136 baris transaksi × 4.065 kolom produk**.

4. Penerapan Algoritma & Alasan Penyesuaian Parameter

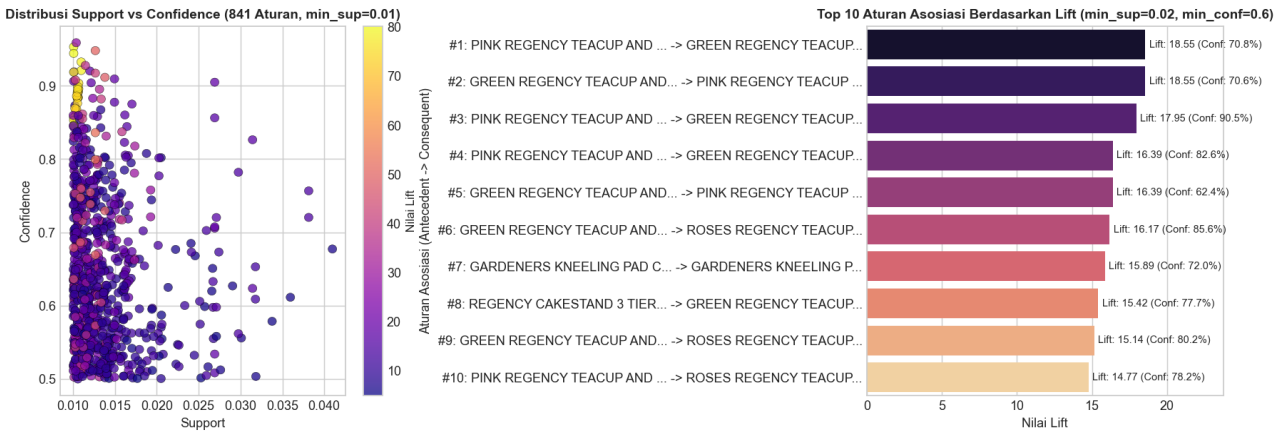
Ekstraksi *frequent itemset* dilakukan menggunakan algoritma **FP-Growth** dan **Apriori**. Pada titik awal (**min_support = 0,01** dan **min_confidence = 0,50**), kedua algoritma menghasilkan hasil identik yaitu **1.853 frequent itemsets** dan **841 aturan asosiasi** (Apriori: 1,39 detik; FP-Growth: 4,68 detik). Karena 841 aturan terlalu banyak dan didominasi kombinasi varian item berfrekuensi rendah (~1% transaksi seperti *Herb Marker*), dilakukan penyesuaian parameter ke **min_support = 0,02** dan **min_confidence = 0,60** sehingga diperoleh **31 aturan inti** pada produk berdaya jual tinggi.

Min Support	Min Confidence	Frequent Itemsets	Jumlah Aturan	Rata-rata Lift	Maks Lift	Karakteristik & Evaluasi Parameter
0,010	**0,50**	**1.853**	**841 aturan**	17,53	**80,22**	**Titik Awal:** Sensitif terhadap item spesifik, terlalu banyak aturan redundan.
0,010	0,60	1.853	498 aturan	20,02	80,22	Support rendah dengan penyaringan probabilitas bersyarat lebih ketat.
0,015	0,50	695	177 aturan	12,89	37,89	Support menengah, mulai menyaring produk musiman berfrekuensi <1,5%.
0,015	0,60	695	94 aturan	15,11	37,89	Kombinasi moderat dengan tingkat akurasi aturan asosiasi yang kuat.
0,020	0,50	376	61 aturan	10,99	18,55	Fokus pada item populer yang dibeli minimal pada 403 transaksi.
0,020	**0,60**	**376**	**31 aturan**	12,01	**18,55**	**Parameter Terfokus:** Ringkas, bebas redundansi, berdampak bisnis luas.

5. Evaluasi Aturan Asosiasi (Support, Confidence, dan Lift)

Tabel berikut merangkum aturan asosiasi terbaik berdasarkan nilai **Lift** baik pada **Titik Awal (min_support = 0,01; min_confidence = 0,5)** maupun pada **Parameter Terfokus (min_support = 0,02; min_confidence = 0,6)**:

Kategori	Antecedents (Jika Membeli)	Consequents (Maka Membeli)	Support	Confidence	Lift
Awal #1 (sup 0,01)	HERB MARKER PARSLEY, HERB MARKER ROSEMARY	HERB MARKER THYME	0,0101	94,42 %	**80,22**
Awal #2 (sup 0,01)	HERB MARKER THYME	HERB MARKER PARSLEY, HERB MARKER ROSEMARY	0,0101	85,65 %	**80,22**
Awal #3 (sup 0,01)	HERB MARKER PARSLEY, HERB MARKER THYME	HERB MARKER ROSEMARY	0,0101	95,31 %	**79,96**
Terfokus #1 (sup 0,02)	PINK REGENCY TEACUP AND SAUCER	GREEN REGENCY TEACUP AND SAUCER, ROSES REGENCY TEACUP AND SAUCER	0,0269	70,76 %	**18,55**
Terfokus #2 (sup 0,02)	PINK REGENCY TEACUP AND SAUCER, ROSES REGENCY TEACUP AND SAUCER	GREEN REGENCY TEACUP AND SAUCER	0,0269	90,48 %	**17,95**
Terfokus #3 (sup 0,02)	GARDENERS KNEELING PAD CUP OF TEA	GARDENERS KNEELING PAD KEEP CALM	0,0271	72,03 %	**15,89**
Terfokus #4 (sup 0,02)	GREEN REGENCY TEACUP AND SAUCER, REGENCY CAKESTAND 3 TIER	ROSES REGENCY TEACUP AND SAUCER	0,0203	80,16 %	**15,14**
Terfokus #5 (sup 0,02)	CHARLOTTE BAG PINK POLKADOT	RED RETROSPOT CHARLOTTE BAG	0,0259	70,26 %	**13,68**



Sebaran Support vs Confidence pada 841 Aturan Awal (Kiri) & Top 10 Aturan Terfokus Berdasarkan Lift (Kanan)

6. Interpretasi Tiga Aturan Terbaik dalam Konteks Bisnis Ritel

- **1. Koleksi Lini Produk Lengkap — Herb Marker Series (Lift = 80,22; Conf = 94,42%) & Regency Teacup Trio (Lift = 18,55; Conf = 70,76%–90,48%):** Pelanggan yang membeli dua varian *Herb Marker* (*Parsley & Rosemary*) memiliki probabilitas **94,42%** membeli *Herb Marker Thyme* (80,22x lebih tinggi dari peluang acak). Demikian pula pada parameter terfokus, pembeli *Pink Regency Teacup* memiliki probabilitas **70,76%** membeli kedua varian lainnya (*Green & Roses*) sekaligus. **Implikasi Bisnis:** Karena pelanggan didominasi pedagang grosir (*wholesalers*), mereka melengkapi seluruh variasi warna/jenis dalam satu seri untuk dipajang di toko ritel mereka. Perusahaan dapat menerapkan **paket bundling lengkap (Complete Set Bundle)** guna meningkatkan nilai pesanan rata-rata (*Average Order Value*).
- **2. Cross-Selling Produk Dekorasi Taman — Gardeners Kneeling Pad Cup of Tea → Keep Calm (Support = 2,71%; Conf = 72,03%; Lift = 15,89):** Sebanyak 72,03% transaksi yang memuat alas lutut berkebun motif *Cup of Tea* juga membeli motif *Keep Calm* (546 invoice). **Implikasi Bisnis:** Pada katalog web ritel, sistem rekomendasi (*"Frequently Bought Together"*) pada halaman produk dapat langsung menawarkan desain pasangannya dengan diskon grosir bertingkat.
- **3. Pasangan Produk Komplementer — Regency Cakestand 3 Tier + Teacup (Lift = 15,14; Conf = 80,16%) & Charlotte Bag (Lift = 13,68; Conf = 70,26%):** Pembeli tempat kue 3 tingkat (*Regency Cakestand*) bersama *Green Regency Teacup* memiliki probabilitas **80,16%** untuk membeli *Roses Regency Teacup*. **Implikasi Bisnis:** Dalam manajemen pergudangan (*warehouse slotting*), lini produk *Regency* dan variasi *Charlotte Bag* sebaiknya ditempatkan di lokasi rak yang berdekatan guna mempercepat *order picking*, serta pemesanan ulang stok (*reorder point*) antar varian disinkronkan.

7. Kesimpulan

1. Pembersihan data berhasil mengeliminasi **11.216 baris tidak valid** (deskripsi kosong, pembatalan bersimbol 'C', dan kuantitas ≤ 0), menyisakan **530.693 baris dan 20.136 invoice bersih** yang siap diolah dengan matriks one-hot.
2. Penyesuaian parameter dari titik awal (*min_support = 0,01; min_confidence = 0,5* dengan 841 aturan) menjadi **min_support = 0,02 dan min_confidence = 0,6** efektif menyaring aturan redundan menjadi **31 aturan utama** berkualitas tinggi.
3. Pola pembelian dalam dataset **Online Retail** didominasi oleh perilaku **pembelian seri/varian produk sejenis dan komplementer secara kolektif** (*Herb Marker, Regency Teacup & Cakestand, Gardeners Kneeling Pad, Charlotte Bag*) yang mencerminkan pola belanja pelanggan grosir (*wholesaler*).