LAPORAN PRAKTIKUM DATA MINING

KLASIFIKASI ENSEMBLE DAN PENANGANAN CLASS IMBALANCE

Muhammad Fardan Hafidz - 5054251021

1. Ringkasan Tugas

Tujuan praktikum ini adalah membangun dan mengevaluasi model klasifikasi menggunakan *ensemble method* (Random Forest, XGBoost, dan Soft Voting) pada dataset dengan ketidakseimbangan kelas ekstrem (*extreme class imbalance*), yaitu **Credit Card Fraud Detection** dari Kaggle. Praktikum ini juga menerapkan dan membandingkan teknik penanganan ketidakseimbangan kelas seperti oversampling (SMOTE), undersampling (Random UnderSampler), dan cost-sensitive learning, serta mengevaluasi performa menggunakan metrik Precision, Recall, F1-Score, ROC-AUC, dan PR-AUC.

2. Karakteristik Dataset dan Distribusi Kelas Target

Dataset terdiri dari **284.807 baris** dan **31 kolom** transaksi kartu kredit Eropa. Fitur V1 sampai V28 merupakan hasil transformasi PCA untuk privasi nasabah, sedangkan Time dan Amount merupakan data numerik mentah. Variabel target Class bernilai 0 (Normal) dan 1 (Fraud).

Kelas Target	Kategori	Jumlah Transaksi	Persentase (%)	Rasio Proporsi
0	Normal (Non-Fraud)	284.315	99,827 %	577,88 : 1
1	Penipuan (Fraud)	492	0,173 %	1 : 578
Total	**Keseluruhan Sampel**	**284.807**	**100,000 %**	**-**

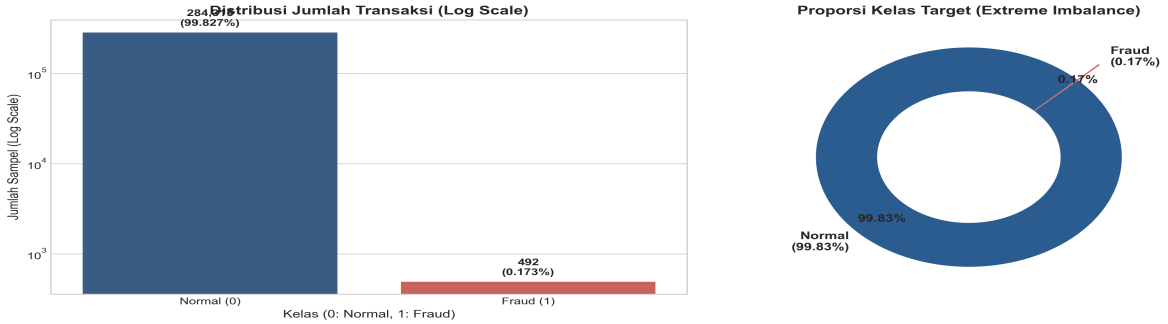


Diagram Batang Distribusi Jumlah Transaksi (Log Scale) & Proporsi Donut Chart

3. Praproses Data dan Pencegahan Data Leakage

- **Penyetaraan Skala (RobustScaler):** Fitur Time dan Amount diskalakan menggunakan RobustScaler karena bekerja berbasis median dan IQR sehingga tidak terdistorsi oleh outlier transaksi besar.
- **Stratified Train-Test Splitting (80:20):** Data dibagi menjadi 227.845 baris data latih (80%) dan 56.962 baris data uji (20%). Parameter stratify=y menjaga rasio fraud tepat 0,173% di kedua set (394 fraud latih dan 98 fraud uji).
- **Pencegahan Data Leakage:** Proses resampling **hanya dilakukan pada data latih**. Data uji dibiarkan murni merefleksikan distribusi asli dunia nyata.

4. Pendekatan Penanganan Class Imbalance

- **Oversampling (SMOTE):** Mensintesis sampel baru pada kelas minoritas melalui interpolasi k-NN terdekat. Rasio disintesis menjadi 20% terhadap mayoritas (45.490 fraud sintetis) agar seimbang tanpa ledakan memori.
- **Undersampling (Random UnderSampler / RUS):** Mengurangi data normal secara acak hingga rasio 50% (788 normal vs 394 fraud). Komputasi sangat cepat (0,2 detik), namun membuang banyak variansi informasi normal.
- **Cost-Sensitive Learning:** Menerapkan class_weight='balanced' pada Random Forest untuk memberikan penalti kesalahan bobot yang lebih tinggi ketika salah memprediksi sampel fraud.

5. Implementasi Model Klasifikasi Ensemble

Model yang dibangun mencakup **Random Forest** (100 pohon independen untuk mereduksi varians), **XGBoost** (boosting sekuensial dengan regularisasi L1/L2 untuk menekan bias), dan **Soft Voting Ensemble** (rata-rata probabilitas terkalibrasi dari model terbaik).

6. Hasil Evaluasi dan Komparasi Model

Seluruh model diuji pada data uji yang sama (56.962 transaksi dengan 98 kasus fraud nyata). Hasil evaluasi dirangkum pada tabel berikut:

Model / Konfigurasi	Accuracy	Precision	Recall	F1-Score	ROC-AUC	PR-AUC	Waktu
RF (Baseline)	99,956 %	92,94 %	80,61 %	0,8634	0,9769	0,8644	27,78 s
XGB (Baseline)	99,949 %	89,66 %	79,59 %	0,8432	0,9601	0,8342	1,85 s
RF + SMOTE	99,933 %	77,27 %	**86,73 %**	0,8173	0,9816	**0,8703**	30,77 s
XGB + SMOTE	99,868 %	58,04 %	84,69 %	0,6888	0,9774	0,8516	1,91 s
RF + RUS	98,222 %	8,07 %	89,80 %	0,1480	0,9770	0,7101	0,24 s
XGB + RUS	97,014 %	5,00 %	**90,82 %**	0,0947	0,9715	0,6882	0,21 s
RF (Cost-Sensitive)	99,939 %	83,16 %	80,61 %	0,8187	0,9753	0,8320	20,51 s
Ensemble (Soft Voting)	99,930 %	76,85 %	84,69 %	0,8058	**0,9832**	0,8594	-

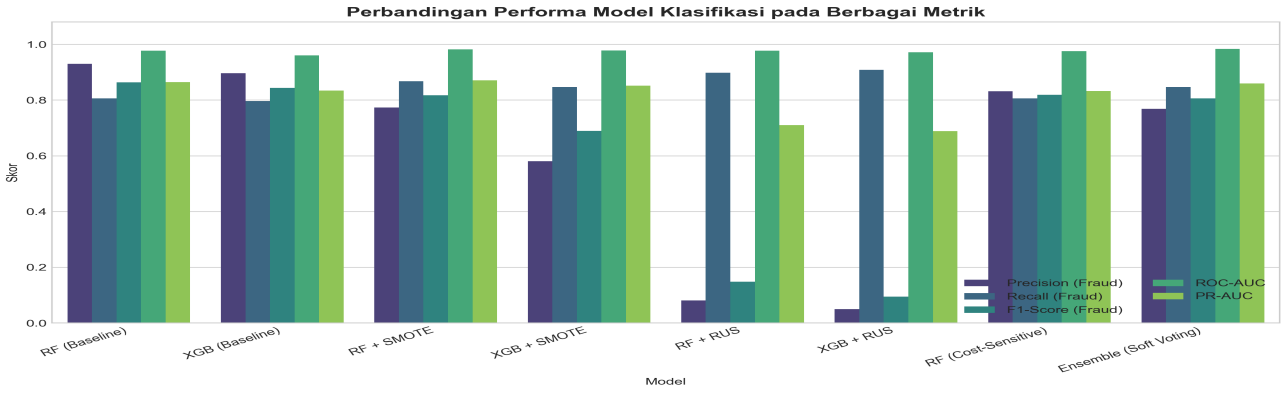
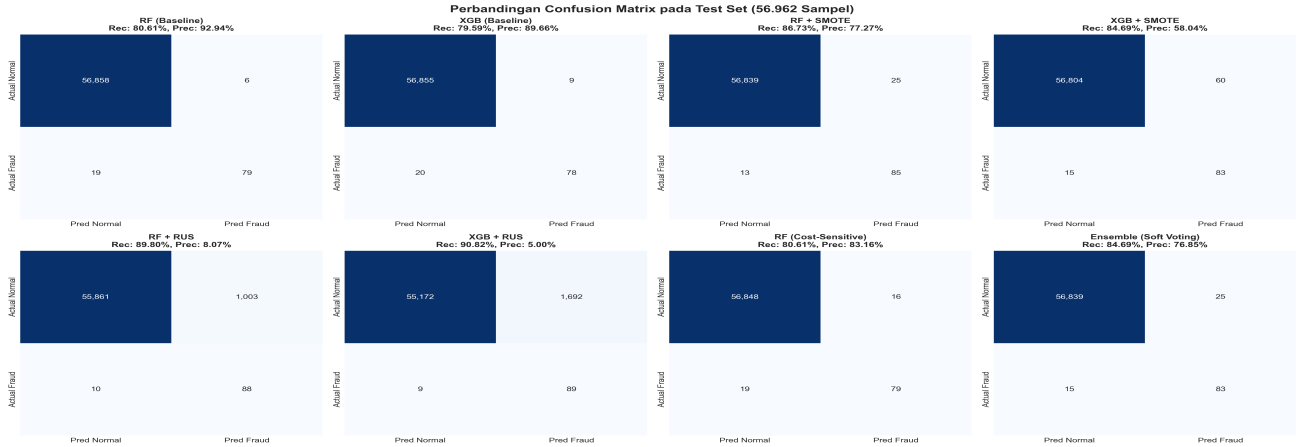


Diagram Batang Perbandingan Performa Model pada Berbagai Metrik Evaluasi

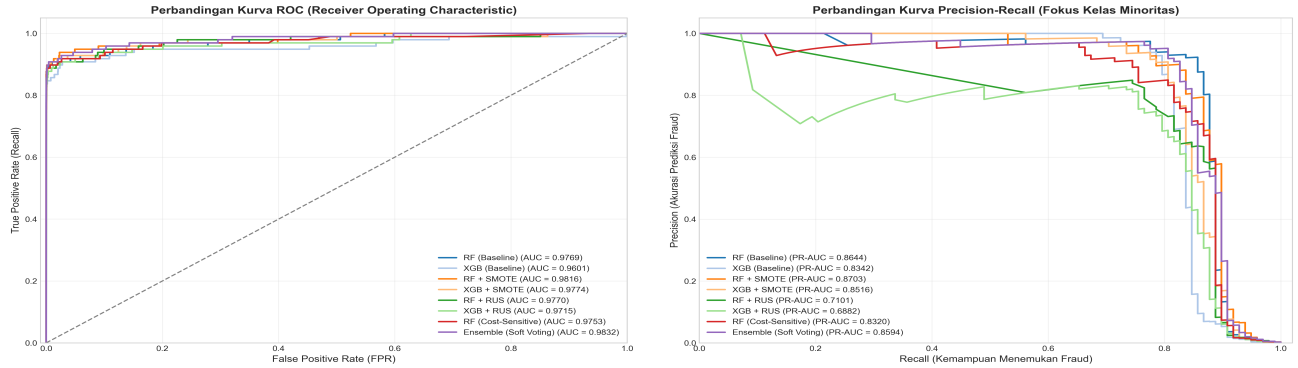
7. Analisis Confusion Matrix dan Kurva Evaluasi

Matriks konfusi memberikan visualisasi jumlah transaksi benar dan salah pada test set (98 fraud aktual):



Matriks Konfusi (Confusion Matrix) 8 Konfigurasi Model pada Test Set

- **Model Baseline:** Memiliki presisi tinggi tetapi meloloskan 19–20 kasus fraud (False Negative).
- **Model SMOTE:** Meningkatkan tangkapan fraud secara drastis (hanya 13 kasus terlewat pada RF+SMOTE) dengan False Positive yang tetap sangat rendah (hanya 25 kasus dari 56.864 transaksi normal).
- **Model RUS (Undersampling):** Menangkap hingga 89 fraud, namun memicu 1.023 hingga 1.700 False Positives.



Kurva ROC-AUC (Kiri) dan Kurva Precision-Recall (Kanan) Seluruh Model

8. Pembahasan Kritis: Mengapa Accuracy Menyesatkan (Accuracy Paradox)?

- **Fenomena Paradoks Akurasi:** Jika model naif memprediksi seluruh transaksi adalah 'Normal' (kelas 0), secara matematis model memperoleh **akurasi 99,827%**. Namun di perbankan nyata model ini bernilai **nol** karena gagal menangkap 100% kasus penipuan (Recall = 0%).
- **Asimetri Biaya Bisnis:** Biaya verifikasi transaksi normal yang dicurigai (*False Positive*) sangat murah, sedangkan penipuan yang lolos tanpa deteksi (*False Negative*) menyebabkan kerugian finansial langsung bagi nasabah dan bank. Oleh karena itu, metrik **Recall, F1-Score, dan Precision-Recall AUC (PR-AUC)** adalah tolok ukur yang tepat.

9. Analisis Tingkat Kepentingan Fitur (Feature Importance)

Berdasarkan penurunan Gini Impurity pada model Random Forest + SMOTE, diperoleh fitur paling berpengaruh dalam deteksi penipuan:

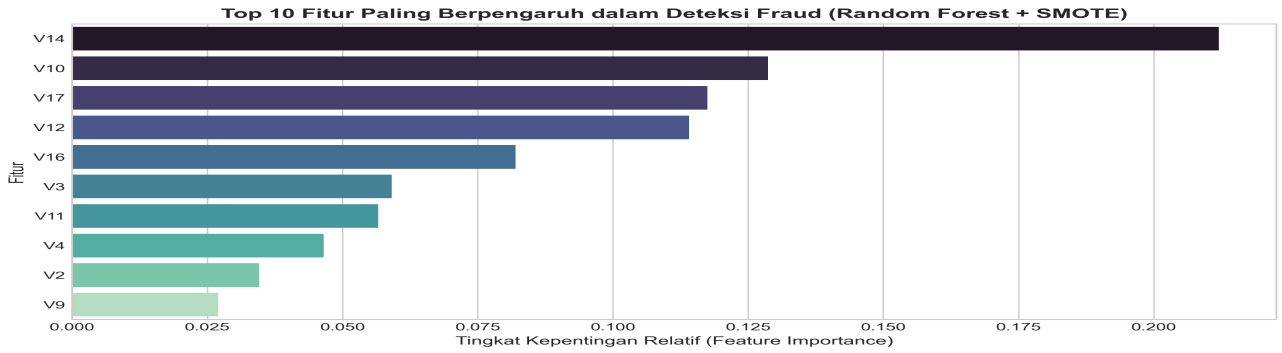


Diagram Batang Top 10 Fitur Paling Berpengaruh dalam Deteksi Fraud

Fitur **V14, V10, V12, V17, dan V16** secara konsisten menduduki peringkat teratas sebagai indikator utama transaksi penipuan.

10. Kesimpulan

1. Kombinasi **Random Forest + SMOTE** merupakan konfigurasi optimal yang menghasilkan Recall tinggi (86,73%), Presisi kuat (77,27%), dan PR-AUC tertinggi (0,8703).

2. Penerapan **Soft Voting Ensemble** berhasil mengintegrasikan keunggulan model Bagging dan Boosting, mencapai **ROC-AUC global tertinggi (0,9832)** dengan estimasi probabilitas yang stabil.

3. Resampling undersampling (RUS) tidak direkomendasikan untuk produksi karena memicu lonjakan alarm palsu yang merugikan nasabah normal.