

LAPORAN PRAKTIKUM DATA MINING

PREPROCESSING DATA HOUSE PRICES

Muhammad Fardan Hafidz - 5054251021

1. Ringkasan Tugas

Tujuan dari praktikum ini adalah melakukan pemrosesan awal (preprocessing) dan pembersihan data pada dataset **House Prices: Advanced Regression Techniques**. Dataset awal terdiri dari 1.460 baris dan 81 fitur yang menggambarkan berbagai aspek rumah tinggal di Ames, Iowa. Proses preprocessing dilakukan agar data siap digunakan untuk pemodelan regresi prediksi harga rumah.

2. Pembersihan Data (Data Cleaning)

Pembersihan data mencakup penanganan nilai yang hilang (missing values) serta penyesuaian tipe data:

- **Penanganan Missing Values Kategorikal:** Kolom seperti PoolQC, MiscFeature, Alley, dan Fence yang memiliki nilai hilang lebih dari 80% diisi dengan kategori "None" karena nilai hilang menandakan ketiadaan fasilitas tersebut.
- **Imputasi Fitur Numerik:** Fitur LotFrontage diimputasi menggunakan nilai median berdasarkan kelompok Neighborhood untuk menjaga akurasi distribusi lokal.
- **Pembersihan Fitur Garasi dan Basement:** Nilai hilang pada fitur numerik garasi/basement diisi angka 0, sedangkan fitur kategorikalnya diisi "None".

3. Deteksi dan Penanganan Outlier

Pemeriksaan scatter plot antara `GrLivArea` dan target `SalePrice` menunjukkan adanya beberapa outlier ekstrem. Dua sampel dengan luas area bangunan sangat besar (> 4.000 sqft) namun memiliki harga jual relatif rendah dihapus untuk menghindari efek penyimpangan pada estimasi model regresi.

4. Transformasi Data

Untuk memenuhi asumsi normalitas dan meningkatkan performa model:

- **Transformasi Logaritmik Target:** Variabel target `SalePrice` memiliki skewness positif (menceng ke kanan), sehingga ditransformasi menggunakan `log1p` agar berdistribusi mendekati normal.
- **Encoding Variabel Kategorikal:** Variabel ordinal diubah menjadi nilai integer hierarkis, sedangkan variabel nominal di-encode menggunakan One-Hot Encoding.
- **Penataan Fitur Skewed:** Fitur numerik dengan skewness $> 0,75$ juga diberikan transformasi logaritmik (Box-Cox / `log1p`).

5. Reduksi Dimensi dan Rekayasa Fitur

Dibuat beberapa fitur baru untuk menggabungkan informasi terkait, seperti `TotalSF` (total luas basement, lantai 1, dan lantai 2) serta `TotalBaths` (total jumlah kamar mandi). Fitur dengan korelasi sangat rendah terhadap target atau yang didominasi satu nilai ($>99.5\%$) direduksi/dihapus.

6. Ringkasan Dataset Akhir

- Setelah seluruh tahapan preprocessing diselesaikan, dataset akhir siap digunakan dengan karakteristik berikut:

Metrik / Parameter	Keterangan / Nilai
Jumlah Baris (Sampel)	1.458 sampel (2 outlier dibuang)
Jumlah Fitur (Setelah Encoding)	220+ fitur encoded
Missing Values Sisa	0% (Seluruh missing value telah diimputasi)

Status Distribusi Target	Mendekati normal (Log-transformed)
--------------------------	------------------------------------

7. Kesimpulan

Tahapan preprocessing data merupakan langkah krusial dalam pipeline Data Mining. Dengan menangani nilai hilang, menghapus outlier ekstrem, mentransformasi variabel yang skewed, serta menerapkan encoding yang sesuai, dataset House Prices kini telah bersih dan terstruktur dengan baik. Dataset bersih ini siap digunakan untuk pemodelan regresi (seperti Ridge, Lasso, XGBoost, atau LightGBM) untuk memprediksi harga rumah secara akurat.