

LAPORAN PRAKTIKUM DATA MINING

Muhammad Fardan Hafidz 5054251021

1. Ringkasan Tugas

Tujuan dari tugas ini adalah mengumpulkan data teks pidato presiden dari situs resmi Kementerian Sekretariat Negara (setneg.go.id) dan mengolahnya agar siap dianalisis. Proses pengambilan data dilakukan otomatis menggunakan program Python. Dari penelusuran halaman arsip, berhasil dikumpulkan 2.972 link artikel. Setelah kontennya diunduh dan dibersihkan dari duplikasi, **diperoleh total 2.872 row dataset naskah pidato dari rentang tahun 2006 sampai 2026.**

Data yang sudah terkumpul kemudian diolah untuk melihat hal-hal menarik, seperti perbandingan gaya pidato antar presiden, bahasa yang digunakan, negara yang sering dikunjungi, tren program Makan Bergizi Gratis (MBG), dan pola kata yang paling sering dipakai.

2. Langkah Pengambilan Data (Web Scraping)

Proses scraping dibagi menjadi dua tahapan utama yang dibuat rapi dan tidak membebani sistem:

- **Tahap 1 - Mengambil Semua URL (Crawling):** Program membuka halaman daftar pidato secara bertahap (kelipatan 10). Jika halaman berikutnya kosong atau menghasilkan error 404, program otomatis berhenti. Semua link disimpan di file teks `all_speech_urls.txt` sebagai backup.
- **Tahap 2 - Mengambil Isi Naskah (Ekstraksi Detail):** Agar proses cepat, penarikan data menggunakan teknik multithreading (25 proses berjalan bersamaan) dan memanfaatkan Session agar koneksi internet tetap tersambung tanpa perlu membuka ulang dari awal.
- **Fitur Pengaman (Resume Checkpoint):** Sebelum scraping dijalankan, program akan mengecek apakah file `presidential_speech_dataset.csv` sudah ada. Jika ada dan isinya belum lengkap, program hanya akan men-download

link yang belum tersimpan saja. Fitur ini sangat berguna agar kita tidak perlu mengulang proses dari awal jika terjadi bug atau connection error.

Struktur Kolom Dataset

Data hasil scraping disimpan dalam format CSV dengan kolom-kolom berikut:

Nama Kolom	Tipe Data	Keterangan
<code>title</code>	Teks (String)	Judul pidato atau berita dari tag judul halaman.
<code>release_date</code>	Tanggal (Datetime)	Tanggal rilis pidato yang sudah diubah ke format standar tahun-bulan-tanggal (YYYY-MM-DD).
<code>location</code>	Teks (String)	Tempat pidato diadakan, baik di dalam negeri maupun luar negeri.
<code>views_count</code>	Angka (Integer)	Jumlah berapa kali artikel pidato tersebut dibaca di situs Setneg.
<code>language</code>	Kategori	Bahasa naskah, yaitu <code>id</code> (Indonesia) atau <code>en</code> (Inggris). Dideteksi menggunakan kata-kata umum (stopwords).
<code>title_word_count</code>	Angka (Integer)	Jumlah kata pada judul pidato.
<code>content_word_count</code>	Angka (Integer)	Jumlah kata di dalam isi naskah pidato.

<code>mbg_mention_count</code>	Angka (Integer)	Berapa kali program Makan Bergizi Gratis (MBG) disebut di naskah.
<code>content_text</code>	Teks Panjang	Isi lengkap naskah pidato yang disimpan untuk keperluan analisis teks selanjutnya.
<code>president_era</code>	Kategori	Era kepemimpinan presiden (SBY, Jokowi, atau Prabowo) berdasarkan tanggal pelantikan resmi.
<code>country</code>	Kategori	Nama negara tempat acara berlangsung berdasarkan pembersihan teks lokasi.

3. Hasil Analisis Data Eksploratif (EDA)

3.1 Ringkasan Angka Statistik

Berikut adalah nilai rata-rata, nilai tengah, dan rentang data dari naskah yang berhasil dikumpulkan:

Ukuran Data		Rata-rata (Mean)	Nilai Tengah (Median)	Nilai Terendah (Min)	Nilai Tertinggi (Max)
Total Dibaca (Views Count)		1.848 kali	1.583 kali	5 kali	29.831 kali
Panjang (Kata)	Judul	12 kata	13 kata	3 kata	37 kata

Panjang Naskah (Kata)	1.131 kata	697 kata	0 kata	12.704 kata
Penyebutan MBG	0,07 kali	0 kali	0 kali	18 kali

Catatan: Terdapat 133 artikel yang memiliki panjang naskah 0 kata. Setelah diperiksa langsung ke situs aslinya, halaman-halaman tersebut ternyata hanya memuat foto kegiatan, link download PDF, atau video dokumentasi tanpa teks naskah pidato tertulis.

3.2 Jumlah Pidato dan Sebaran Panjang Kata per Era Presiden

Berdasarkan tanggal rilisnya, pidato dikelompokkan ke dalam tiga masa kepemimpinan:

- **Era Presiden Joko Widodo (2014 – 2024):** 1.534 pidato (53,4%)
- **Era Presiden Susilo Bambang Yudhoyono (2006 – 2014):** 1.107 pidato (38,6%)
- **Era Presiden Prabowo Subianto (2024 – 2026):** 231 pidato (8,0%)

Dari grafik sebaran kata terlihat bahwa era Presiden SBY memiliki nilai tengah panjang pidato yang lebih tinggi. Hal ini wajar karena pidato beliau lebih banyak berupa naskah resmi, ceramah kenegaraan, atau sambutan panjang. Sementara di era Presiden Jokowi dan Prabowo, banyak naskah berisi keterangan pers langsung di lapangan, tanya-jawab singkat, atau instruksi rapat kerja yang lebih padat dan to-the-point.




Diagram Batang Jumlah Pidato per Era & Boxplot Panjang Kata per Era

3.3 Bahasa Pidato dan Kunjungan ke Luar Negeri

Dari seluruh data yang terkumpul:

- **Bahasa Pengantar:** Sebanyak 95,3% (2.736 pidato) menggunakan Bahasa Indonesia, sedangkan 4,7% (136 pidato) menggunakan Bahasa Inggris. Bahasa Inggris umumnya digunakan saat presiden menghadiri KTT internasional (seperti KTT ASEAN, G20, BRICS) atau forum bisnis investor global.
- **Kunjungan Luar Negeri:** Dari naskah yang mencantumkan lokasi resmi di luar negeri, negara yang paling sering menjadi lokasi pidato adalah Amerika Serikat (13 pidato), disusul oleh Rusia (7 pidato), Jepang (7 pidato), Korea Selatan (7 pidato), dan Arab Saudi (5 pidato).





Diagram Lingkaran Bahasa Pidato & Diagram Batang Top 10 Negara Luar Negeri

3.4 Analisis Tren Program Makan Bergizi Gratis (MBG) & Minat Pembaca

Analisis terhadap kata kunci program MBG menunjukkan pola yang sangat spesifik:

- Kata kunci MBG sama sekali tidak pernah muncul (bernilai 0) pada masa kepemimpinan Presiden SBY maupun Presiden Jokowi.
- Sebanyak 217 kali penyebutan MBG hanya ditemukan pada 41 naskah di era Presiden Prabowo Subianto.
- Grafik garis tren memperlihatkan bahwa istilah ini mulai muncul pada akhir tahun 2024, lalu meningkat tajam sepanjang tahun 2025 dan 2026 seiring berjalannya program Badan Gizi Nasional.

- Sedangkan grafik titik (scatter plot) menunjukkan tidak ada hubungan langsung antara panjangnya naskah dengan jumlah pembaca (views). Pidato yang sangat panjang tidak otomatis dibaca lebih banyak dibandingkan pidato singkat yang topiknya sedang hangat.



Grafik Garis Tren MBG per Kuartal & Scatter Plot Panjang Naskah vs Views

3.5 Analisis Pasangan Kata (N-Gram / Bigram)

Untuk mengetahui topik utama masing-masing presiden, dilakukan analisis pasangan dua kata berurutan (bigram). Kata-kata umum seperti "dan", "di", salam pembuka, dan kata ulang (seperti "negara-negara" atau "hati-hati") sudah dibersihkan terlebih dahulu agar hasilnya bermakna:

- **Era SBY:** Sering memuat kata-kata tentang diplomasi, hukum, dan stabilitas nasional, seperti "*kerja sama*", "*tanah air*", dan "*masa depan*".
- **Era Jokowi:** Sangat kental dengan fokus pembangunan fisik dan pemulihan, seperti "*rumah sakit*", "*pertumbuhan ekonomi*", dan "*jalan tol*".
- **Era Prabowo:** Banyak mengangkat konsep kedaulatan, lembaga, dan kesejahteraan rakyat, seperti "*merah putih*", "*ketua umum*", dan "*kepala badan*".




Diagram Batang Karakteristik Narasi / Top Bigram per Presiden

4. Kesimpulan

Proses scraping bisa terselesaikan berkat metode bertahap dan sistem penyimpanan sementara yang aman. Dataset pidato kepresidenan ini sudah bersih, terstruktur, dan berhasil menggambarkan transisi topik serta gaya komunikasi dari tiga era presiden Republik Indonesia secara jelas dan objektif. Data teks lengkap yang sudah tersimpan juga siap digunakan untuk analisis lanjutan, seperti pengelompokan topik (topic modeling) atau analisis sentimen.